

PDC Semana 1 - Infraestrutura de Inferência

Responsável pela Keyword: Marcos Vinicius Barreira Queiroz

- Servir é diferente de treinar.
- O que é uma infraestrutura de inferência ?
- O caminho de um pedido: fila, prefill, decode, resposta.
- O que é um servidor de inferência e por que não é só chamar generate().


inferência

Uma breve explicação

O que é inferência ?

- Significa **deduzir**, chegar a uma conclusão por **meio do raciocínio**.
- Na leitura de um texto, precisamos inferir (deduzir) **por meio das pistas** que o próprio texto deixa. Para isso, é necessário ativar **nosso conhecimento de mundo**.

Fazendo inferências em uma charge



Servir é diferente de treinar

Inferência e backpropagation

Para darmos início a este raciocínio, devemos entender o que é **backpropagation**

- **Em um modelo de linguagem:** ele é utilizado tanto em SLMs quanto em LLMs, pois ambos são baseados na arquitetura de redes neurais (geralmente Transformers) e precisam desse processo para aprender.


A principal diferença entre inferência e backpropagation está na direção do fluxo de dados e no objetivo do processo: um serve para usar o modelo e o outro para treinar o modelo.

Inferência (Servir)

Durante a inferência, você fornece um texto para o SLM, o modelo processa essas palavras através de suas camadas matemáticas utilizando os pesos que ele já aprendeu.

Backpropagation (Treinar)


O backpropagation ocorre exclusivamente na fase de treino ou de ajuste fino (fine-tuning). É o mecanismo de aprendizado usado durante o seu treinamento.



Infraestrutura de inferência

O que de fato é ?

Uma infraestrutura de inferência em IA é o **conjunto de hardware e software** responsável por **colocar** um modelo de inteligência artificial já treinado **em funcionamento** para **gerar respostas, previsões ou decisões** em tempo real.



A infra tem quatro camadas principais:

- **Hardware:** **servidores com GPUs** (ou NPUs/aceleradores) dentro de datacenters, com **muita memória e rede rápida entre si**.
- **Servidor de modelo:** **um programa** (como vLLM, TGI, TensorRT-LLM) que **carrega o modelo na GPU**, gerencia a memória e **organiza** as requisições de forma **eficiente**.
- **Orquestração e escalabilidade:** mecanismos que **percebem** quando está chegando **muito** pedido e **ligam mais servidores** (ou migram pedidos para não sobrecarregar).
- **API:** a “porta de entrada” pela qual aplicativos **enviam textos** e **recebem respostas**

Utilização no dia a dia...

- Você usa infraestrutura de inferência toda vez que **conversa com um chatbot**, usa **tradução automática**, recebe sugestão de texto no e-mail ou pergunta algo a um **assistente de voz**.

O caminho de um pedido: fila, prefill, decode, resposta.


Detalhes do pipeline de uma requisição

Detalhando o processo

- **Fila:** Quando uma requisição chega ao servidor, ela não vai direto para a GPU, primeiro ela entra em uma fila de espera. A memória da GPU (VRAM) é finita, o servidor atua como um maestro: ele avalia se há blocos de memória física livres o suficiente na GPU para acomodar esse novo prompt.
- **Prefill:** É a fase inicial onde o modelo lê e "entende" todo o texto que o usuário enviou. O prompt inteiro é processado de uma só vez, em paralelo. O modelo realiza multiplicações de matrizes gigantes para calcular as representações de cada palavra e entender a relação entre elas. Esta fase gera o primeiro token da resposta e, crucialmente, cria o KV Cache.

Detalhando o processo

- **Decode:** É a fase de geração propriamente dita. O modelo começa a cuspir a resposta. É aqui que o SLM brilha, como o modelo é menor, há menos pesos para transferir da VRAM para o processador a cada token gerado, tornando a fase de Decode extremamente veloz em comparação a um LLM gigante.
- **Resposta:** É a devolução dos dados para o usuário ou para a aplicação que fez a chamada.



Gargalos



O que é um servidor de inferência

Por que não é só chamar generate()

O papel do servidor de inferência

- Em resumo, o **servidor de inferência** é o componente responsável por **receber** as requisições, **executar** o modelo e **devolver** as respostas.
- O servidor avalia a **carga da GPU** a cada iteração, ou seja, **a cada milissegundo** após gerar um único token. Se a requisição "A" terminar no token 15, **ela é ejetada da GPU** na mesma hora, e a requisição "B" que estava na fila **entra para ocupar aquele espaço** imediatamente.

Exemplo de servidor de inferência: **Ollama**

- **Foco principal:** Desenvolvimento Local e Simplicidade
- **Como funciona na prática:** Funciona de forma similar ao Docker. Com um comando simples (`ollama run llama3`), ele baixa o modelo, aloca o que for possível na memória RAM/vRAM e abre uma API local em segundos no computador do desenvolvedor.




Ollama

Analogia simples

Conceito	Analogia
 SLM	O "cérebro"
 Servidor de inferência	Sistema que coloca o cérebro para trabalhar
 Requisição	Pergunta do usuário
 Fila	Pessoas esperando atendimento
 Prefill	Processamento da pergunta/ contexto
 Decode	Geração da resposta
 Resposta	Resultado entregue ao usuário


Exemplo de arquitetura



O Problema de usar apenas o generate()

- Se você tentar colocar o generate() bruto **direto na produção** do seu aplicativo, é como tentar levar **50 passageiros** para o trabalho usando **apenas um carro de Fórmula 1**. Ele só aguenta uma pessoa por vez, consome combustível de forma **ineficiente para o dia a dia** e, se duas pessoas tentarem entrar juntas, **o sistema quebra**.
- Ele não sabe **gerenciar filas de usuários**, não sabe **dividir a memória** da máquina de forma **inteligente** e não entrega o **texto em partes**, palavra por palavra, na tela do usuário.

A função **só consegue fazer uma requisição por vez. Se chegar uma segunda, ela precisa esperar até a primeira encerrar.**



Perguntas!!!

Para fixar o conhecimento

O que de fato é uma infraestrutura de inferência no contexto dos SLM's

O que de fato é uma infraestrutura de inferência no contexto dos SLM's

Resposta: É o conjunto de hardware, software e ferramentas de otimização necessárias para executar modelos de linguagem menores de forma rápida, eficiente e econômica, após eles terem sido treinados.

Qual a diferença entre inferência e backpropagation ?

Qual a diferença entre inferência e backpropagation ?

Resposta: A inferência é a utilização do modelo para gerar texto, enquanto o backpropagation é o mecanismo de aprendizado usado durante o seu treinamento.

O que é um servidor de inferência ?

O que é um servidor de inferência ?

Resposta: É o software e a infraestrutura responsável por executar o modelo e processar as solicitações dos usuários em tempo real.

Obrigado !

Dúvidas ?