
APRESENTAÇÃO

Quantização: Representação Numérica

FP32, FP16, BF16, INT8, INT4, FP4.

A escala, o zero-point e o preço real da compressão.



Beatriz Almeida

Ponto Flutuante

1 bit de sinal + Expoente (magnitude) + Fração (precisão)

FP32 Padrão Ouro

32 bits

- ✓ 8 bits de expoente.
- ✓ 23 bits de fração.
- ✓ Extrema precisão decimal.

FP16 Risco de Overflow

16 bits

- Apenas 5 bits de expoente.
- 10 bits de fração.
- Menor alcance numérico.

BF16 Padrão IA

16 bits

- Mantém 8 bits de expoente.
- Sacrifica a fração (7 bits).
- Imune a overflow fácil.

Descendo para os Inteiros

INT8

256

Valores possíveis (-128 a 127)

INT4


16

Valores possíveis (-8 a 7)

Como mapear decimais nisso? **Escala e Zero-point.**

Escala e Zero-Point

Dois números bastam para mapear qualquer intervalo real em inteiros: a escala define o tamanho do passo; o zero-point diz qual inteiro representa exatamente o zero.



$$\text{escala} = (6 - (-2)) / 255 \approx 0,0314 \quad \bullet \quad \text{zero-point} = 0 - \text{round}(-2 / 0,0314) = 64$$

SIMÉTRICO

zero-point = 0. Usado quando o intervalo é centrado em zero — o caso típico dos pesos de uma rede neural.

ASSIMÉTRICO

zero-point $\neq$ 0. Necessário quando o intervalo não é centrado em zero — como ativações após ReLU ou GELU.

Matemática da Conversão

QUANTIZAÇÃO (COMPACTAR NA MEMÓRIA)

$$\text{INT} = \text{round} \frac{\text{Valor}}{\text{Escala}} + \text{Zero_point}$$


DEQUANTIZAÇÃO (RECUPERAR PARA O CÁLCULO)

$$\text{Valor} = (\text{INT} - \text{Zero_point}) \times \text{Escala}$$

 **Preço:** A função de arredondamento (round) destrói a precisão original de forma irreversível.

Onde Mora o Erro

Todo valor real é arredondado para o degrau mais próximo. A distância até esse degrau é o erro de quantização — ele nunca desaparece, só fica pequeno o suficiente para não importar.



Regra prática: quanto menor a escala (mais bits), menor o erro máximo — e mais memória o formato ocupa.

Pratique: Zero-Point em Ação

PERGUNTA Uma ativação ReLU está sempre no intervalo $[0, 6]$. Mapeie o valor **4,5** para UINT8 $[0, 255]$.

1. ESCALA

$$(6-0)/255 = 0,0235$$

2. ZERO-POINT

➤ $0 - \text{round}(0) = 0$

3. QUANTIZAR

➤ $\text{round}(4,5/0,0235) = 191$

4. DEQUANTIZAR

➤ $191 \times 0,0235 = 4,49$

Resultado: armazena-se 191 em UINT8. Ao recuperar: $191 \times 0,0235 = 4,49$ — erro de apenas 0,01 sobre 4,5 ($\approx 0,2\%$).

ATIVAÇÃO ReLU → $[0, 6]$

zero-point = 0. O intervalo já começa exatamente em zero, então nenhum deslocamento é necessário.


ATIVAÇÃO GELU → $[-2, 6]$

zero-point = 64. Como no exemplo da régua numérica: o intervalo cruza o zero fora do centro, então é preciso deslocar.


SÍNTESE

O Preço da Compressão

Cada bit removido é trocado por velocidade e memória. A pergunta certa nunca é “perde-se algo?” — é sempre “esse erro é aceitável para a minha aplicação?”



Alocação de bits: alcance (expoente) vs. precisão (fração)




Memória necessária para um modelo de 7 bilhões de parâmetros

INOVAÇÃO

Fronteira FP4

Por que FP4 no lugar de INT4?

- Ponto flutuante comprimido em apenas 4 bits.
- Distribuição **não linear** dos 16 valores.
- Alta densidade de precisão próxima ao zero.
- Aderência perfeita aos pesos de LLMs (curva de sino).




Distribuição de pesos ideal.
Maior precisão ao redor de Zero.



Regra da Vulnerabilidade: Hardware vs Representação

”Como as GPUs modernas executam matemática de matrizes em INT4? O chip faz o cálculo nativamente ou precisa desempacotar tudo para FP16 internamente?”

DISCUSSÃO ABERTA



Erro Aceitável

Alvo: 3,7 em INT8 (Escala: 0,05)

1. DIVIDIR

$$3,7 / 0,05 = 74$$

>

2. ARREDONDAR

$$\text{round}(74) = 74$$

>

3. MEMÓRIA INT8

74

>

4. RECUPERAR

$$74 * 0,05 = 3,7$$

Cenário Perfeito

Para o valor exato de 3,7, o erro cometido é **0.0 (Zero)**. Nenhuma perda ocorreu ao arredondar.

Cenário Real (Ex: 3,72)

Na dequantização, o valor recuperado seria 3,70. Ruído gerado: **0,02**.

Erro relativo: $0,02 / 3,7 \approx 0,54\%$

Veredito Final

Altamente aceitável. Trocar FP32 por INT8 entrega **4x mais velocidade de leitura (RAM)** sem degradar a ativação do LLM.

Regra prática: erros relativos **abaixo de 1%** somem-se ao ruído normal de inferência.